

Clasificación de la calidad y estimación del tamaño de manzanas mediante visión por computador: comparación de modelos clásicos y una red neuronal convolucional

David Alejandro Troya
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
troyaalejandro4@gmail.com

Santiago Morales Cerón
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
Santiagomorales.c15@gmail.com

Juan Esteban Gómez Higidio
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
09juanesteban@gmail.com

Resumen—La clasificación manual de la calidad de frutas es lenta, subjetiva y propensa a errores, lo que genera pérdidas económicas y desperdicio de alimentos. Se desarrolla un sistema de visión por computador que, a partir de la fotografía de una manzana, predice su *calidad* (buena, regular, mala) y estima su *tamaño* (diámetro normalizado y clase pequeño/mediano/grande). Se segmenta la fruta para calcular un descriptor de 49 características de color, textura y defectos *solo sobre la fruta* (invariante al fondo), y se comparan, bajo el mismo protocolo, tres modelos clásicos (regresión logística, SVM-RBF y Random Forest) y una red neuronal convolucional (CNN). Sobre 3006 imágenes (2890 del dataset público y 116 propias), los cuatro modelos alcanzaron un desempeño comparable en prueba (F1-macro 0,94–0,95); por validación cruzada la SVM-RBF fue la mejor (0,967), muy por encima de la línea base logística (0,838). Se sigue la metodología CRISP-DM y se discuten el sesgo de los datos, la validez de los resultados y los aspectos éticos.

Index Terms—visión por computador, clasificación de calidad, segmentación, SVM, Random Forest, CNN, estimación de tamaño, CRISP-DM.

I. INTRODUCCIÓN

En mercados y agroindustrias, la clasificación de productos frescos según madurez, tamaño o defectos se hace de forma manual: un proceso lento, subjetivo y costoso que contribuye a pérdidas y desperdicio de alimentos [1]. Automatizarla con visión por computador permite acelerar el proceso y estandarizar criterios.

Este proyecto desarrolla un sistema que, dada la foto de una manzana sobre fondo simple, entrega dos salidas exigidas por el caso de estudio: (i) la *clase de calidad* en tres categorías (buena, regular, mala) y (ii) una *estimación de tamaño*. La justificación es directa: reducir pérdidas poscosecha tiene impacto económico, social y ambiental. El aporte técnico se concentra en un descriptor de color/textura calculado únicamente sobre la fruta segmentada (evitando que el modelo aprenda el fondo), la comparación rigurosa de cuatro modelos y un análisis crítico de la validez de los resultados.

II. FUNDAMENTOS TEÓRICOS

Espacio HSV e histogramas. El color es el principal indicador de calidad de la fruta. Se trabaja en el espacio HSV, que separa el tono (Matiz) de la intensidad. El histograma normalizado de un canal, $h_b = \frac{1}{N} \sum_p \mathbb{K}[c_p \in \text{bin}_b]$, cumple $\sum_b h_b = 1$ y es invariante al número de píxeles (y a la resolución).

Estandarización (z-score). Cada característica se reescala como $z = (x - \mu)/\sigma$, con μ, σ estimados solo en entrenamiento. Es necesaria para SVM-RBF, la regresión logística y la red neuronal, sensibles a la escala.

Segmentación y tamaño. La fruta se separa del fondo con un umbral de Otsu sobre la distancia al color de fondo (estimado en los bordes). El tamaño se mide con el diámetro equivalente del área segmentada, $d_{eq} = 2\sqrt{A/\pi}$, normalizado por el lado de la imagen (invariante a la resolución).

Modelos. La *regresión logística* (línea base) modela $P(y=k | \mathbf{x})$ con softmax. La *SVM* busca el hiperplano de máximo margen y usa el kernel RBF $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$ para fronteras no lineales [4]. El *Random Forest* promedia múltiples árboles con muestreo aleatorio, reduciendo la varianza. La *CNN* aprende filtros sobre los píxeles mediante capas Conv-ReLU-Pooling y minimiza la entropía cruzada $\mathcal{L} = -\frac{1}{n} \sum_i \sum_k y_{ik} \log p_{ik}$ por retropropagación con Adam [5].

Métricas. A partir de la matriz de confusión se calculan precisión, exhaustividad (*recall*) y $F1 = 2PR/(P + R)$ por clase; se reporta el **F1-macro** (promedio entre clases), adecuado ante el desbalance, validado con validación cruzada estratificada de 5 pliegues.

III. FORMULACIÓN MATEMÁTICA DEL PROBLEMA

Sea $I \in [0, 1]^{H \times W \times 3}$ la fotografía de una manzana sobre fondo simple ($H = W = 128$). El sistema debe construir dos funciones: un *clasificador de calidad* $g : I \mapsto y \in \mathcal{Y} = \{\text{buena, regular, mala}\}$ y un *estimador de tamaño* $h : I \mapsto (d, \hat{s})$, con $d \in [0, 1]$ el diámetro normalizado y $\hat{s} \in \{\text{pequeño, mediano, grande}\}$.

Representación. Se define $\phi = \phi_2 \circ \phi_1$, con $\phi_1(I) = M \in \{0,1\}^{H \times W}$ la máscara de segmentación (umbral de Otsu, Sec. II) y $\phi_2(I, M) = \mathbf{x} \in \mathbb{R}^{49}$ el descriptor de color/textura/defectos calculado solo sobre M . Para los modelos clásicos $g = f_\theta \circ \phi$; para la CNN, $g = f_\theta$ actúa directamente sobre $I \odot M$ redimensionada a 64×64 , de modo que ϕ es la identidad enmascarada y la representación se *aprende* dentro de f_θ en lugar de diseñarse a mano.

Aprendizaje como minimización del riesgo empírico regularizado. Dado $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ($n = 2104$), se busca

$$\theta^* = \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n w_{y_i} \mathcal{L}(f_\theta(\mathbf{x}_i), y_i) + \lambda R(\theta),$$

donde $f_\theta : \mathbb{R}^{49} \rightarrow \Delta^2$ (o $f_\theta : [0,1]^{64 \times 64 \times 3} \rightarrow \Delta^2$ en la CNN) entrega una distribución sobre las 3 clases, $\mathcal{L}$ es la entropía cruzada de la Sec. II, $w_{y_i} = n/(3n_{y_i})$ son los pesos balanceados de clase (compensan el desbalance 1197/638/1171), R es el regularizador propio de cada familia (ℓ_2 en regresión logística; margen y par (C, γ) del kernel en SVM-RBF; profundidad y número de árboles en Random Forest; arquitectura y *weight decay* en la CNN) y Θ es el espacio de hipótesis correspondiente.

Selección de modelo e hiperparámetros (optimización de segundo nivel). Se resuelve por búsqueda en rejilla con validación cruzada estratificada de 5 pliegues, maximizando el F1-macro de la Sec. II:

$$(m^*, \lambda^*) = \arg \max_{(m, \lambda) \in \mathcal{M} \times \Lambda} \frac{1}{5} \sum_{k=1}^5 F1_{\text{macro}}(f^{(m, \lambda)}; D_{\text{val}}^{(k)}),$$

con $\mathcal{M} = \{\text{LogReg}, \text{SVM-RBF}, \text{RF}, \text{CNN}\}$ y Λ la rejilla propia de cada familia (resultado: $m^* = \text{SVM-RBF}$, Tabla I). Nótese que este es un problema de optimización anidado: para cada (m, λ) candidato se resuelve internamente el problema de minimización de θ descrito arriba.

Estimación de tamaño (medición, no aprendizaje). A partir de $M = \phi_1(I)$ se mide el diámetro equivalente normalizado $d = 2\sqrt{A/\pi}/\sqrt{HW}$, $A = \sum_p M_p$ (Sec. II), y se discretiza con umbrales τ_1, τ_2 calibrados sobre la distribución empírica del conjunto: $\hat{s} =$ pequeño si $d < \tau_1$, mediano si $\tau_1 \leq d < \tau_2$, grande si $d \geq \tau_2$, con $\tau_1 = 0,45$ y $\tau_2 = 0,62$.

¿Por qué es un problema complejo de ingeniería? (a) g debe aproximar una función no lineal de alta dimensión— $128 \times 128 \times 3 = 49152$ variables de entrada— hacia 3 clases, sin una regla cerrada conocida; (b) hay que resolver a la vez un problema de representación (ϕ : qué calcular) y uno de aprendizaje (f_θ : qué ajustar) que interactúan entre sí—la Sec. VI muestra que omitir la máscara en ϕ produce una métrica artificialmente alta e inválida (fuga de información del fondo)—; (c) las clases están desbalanceadas y la clase *regular* se construyó de forma sintética, lo que obliga a introducir w_{y_i} y validación estratificada; (d) coexisten cuatro espacios de hipótesis con geometrías y costos de búsqueda distintos, y compararlos limpiamente exige fijar partición, semilla, estandarización y métrica (Sec. IV); (e) la estimación

de tamaño añade una tarea de *medición geométrica* (segmentación y calibración de τ_1, τ_2) acoplada a la de clasificación. Esta formulación conecta directamente con el objetivo del proyecto: producir, a partir de una sola fotografía, las dos salidas exigidas por el caso de estudio bajo un protocolo de comparación reproducible y honesto.

IV. METODOLOGÍA

Se aplicó CRISP-DM (Fig. 1) con evidencia en cada fase. La formulación de la Sec. III guía cada decisión: qué calcular (ϕ), qué familias de modelos comparar ($\mathcal{M}$) y con qué criterio elegir ($F1_{\text{macro}}$ por validación cruzada).

Datos. Se usó el conjunto público *Fruit Quality Classification* de Kaggle [3], subconjunto de manzanas: *buena* (1149, *Apple_Good*) y *mala* (1141, *Apple_Bad*). La clase *regular* se construyó, según indica el caso de estudio, segmentando individualmente cada fruta de la carpeta *Mixed Quality* (177 ejemplares recortados) y aumentándola con transformaciones (volteos, rotaciones, brillo) hasta 600 muestras para reducir el desbalance. Además, se recolectaron y añadieron **116 fotografías propias** tomadas para este proyecto (48 sanas, 38 intermedias y 30 dañadas), como exige el caso de estudio, integradas a las tres clases. En total, **3006 imágenes** (buena 1197, regular 638, mala 1171). Las Figs. 2 muestran la distribución de calidad y tamaño.

Preparación y características. Cada imagen se redimensiona a 128×128 (elimina el sesgo de resolución) y se segmenta la fruta (Fig. 3). Sobre los píxeles de la fruta se calcula un vector de **49 características**: histogramas de H/S/V (16/8/8), media y desviación de R,G,B,H,S,V (12), estadísticos de gradiente (2, textura), proporción de píxeles oscuros y marrones (2, defectos) y entropía de matiz (1). *Calcular las características solo sobre la fruta es una decisión clave*: evita que los modelos aprendan el fondo (césped, mano, mesa) en lugar de la calidad.

Estrategia de solución y alternativas consideradas. La formulación (Sec. III) deja dos preguntas abiertas: (1) ¿basta un descriptor diseñado a mano de 49 variables, o se necesita aprender la representación directamente de los píxeles?, y (2) sobre ese descriptor, ¿qué *forma* de frontera de decisión—lineal, de margen máximo no lineal, o de comité de árboles—ajusta mejor g ? En lugar de asumir una respuesta, se comparan bajo el mismo protocolo cuatro hipótesis representativas: *regresión logística* como **línea base** lineal e interpretable—si un modelo no lineal no la supera con claridad, no se justifica su mayor costo—; *SVM-RBF*, que mediante el kernel K (Sec. II) construye fronteras no lineales en espacios de pocas decenas de dimensiones sin requerir datasets masivos, el escenario típico de un descriptor diseñado a mano [4]; *Random Forest*, robusto a variables en escalas y correlaciones distintas (como ocurre entre histogramas de color contiguos), que reduce varianza promediando árboles y, a diferencia de SVM y CNN, entrega *importancia de características* (Fig. 6) útil para validar si el modelo aprende señales agrónomicamente sensatas; y una *CNN* pequeña (3 bloques convolucionales + 2 capas densas, entrada 64×64 enmascarada, Adam, entropía

Aplicación de CRISP-DM al proyecto




Figura 1. Aplicación concreta de CRISP-DM al proyecto.




Figura 2. Distribución del tamaño medido (arriba) y de las clases de calidad (abajo).

cruzada con pesos [5]), incluida como contraste directo de la hipótesis alternativa (1): aprender ϕ en lugar de diseñarlo. Se descartaron explícitamente *KNN* (sensible a la maldición de la dimensionalidad y a la correlación entre histogramas adyacentes), *Gradient Boosting* (espacio de hiperparámetros más amplio y mayor riesgo de sobreajuste dado el tamaño moderado y el desbalance del dataset, sin ganancia esperada sobre Random Forest) y arquitecturas profundas preentrenadas (*transfer learning* tipo ResNet/EfficientNet, descartadas por la simplicidad del fondo y el tamaño del conjunto; se documentan como trabajo futuro).

Para que la comparación sea válida —y la elección del ganador, defendible— se fijaron partición estratificada 70/30 (2104 entrenamiento, 902 prueba, semilla 42), estandarización ajustada *solo* en entrenamiento, *class_weight* balanceado (w_{y_i} de la Sec. III) y un único criterio de selección automática:



Figura 3. Segmentación de la fruta y estimación de tamaño (diámetro normalizado).

el F1-macro en validación cruzada estratificada de 5 pliegues, que *no* usa el conjunto de prueba —evita que la elección del modelo esté contaminada por los datos sobre los que luego se informa el desempeño final—.

Despliegue. Aplicación en Streamlit que permite cargar una imagen o capturarla con la cámara y muestra calidad, tamaño y segmentación.

V. RESULTADOS

La Tabla I, la Tabla II y la Fig. 4 resumen el desempeño. El modelo se selecciona por validación cruzada (sin usar el conjunto de prueba): la **SVM-RBF fue la mejor (F1-macro CV 0,967)**, seguida de Random Forest (0,950) y la regresión logística (0,856). En el conjunto de prueba los tres mejores modelos quedaron *prácticamente empatados* (SVM 0,949, CNN 0,953, Random Forest 0,944), muy por encima de la línea base (0,838); la cercanía entre CV y prueba indica ausencia de sobreajuste severo. Las matrices de confusión (Fig. 5) muestran que los errores se concentran entre *buena* y *mala*. La importancia de características (Fig. 6) confirma que los descriptores de color (saturación y matiz) son los más decisivos, coherente con la intuición agronómica. La

Cuadro I
RESULTADOS GLOBALES ($n_{prueba} = 902$). EL MEJOR MODELO SE ELIGE
POR F1-MACRO EN VALIDACIÓN CRUZADA (CV).

Modelo	Exactitud	F1-macro	F1-macro CV
Regresión logística	0.837	0.838	0.856
SVM (RBF)	0.948	0.949	0.967
Random Forest	0.943	0.944	0.950
CNN (3 conv.)	0.951	0.953	—

Cuadro II
F1 POR CLASE (PRUEBA).

Modelo	Buena	Regular	Mala
Reg. logística	0.82	0.84	0.85
SVM (RBF)	0.94	0.96	0.95
Random Forest	0.94	0.95	0.95
CNN	0.94	0.96	0.95

proyección PCA (Fig. 7) muestra clases separables con zonas de solape, y la Fig. 8 ilustra predicciones de calidad y tamaño.

VI. ANÁLISIS DE RESULTADOS

¿Generalizan? ¿Hay sobreajuste? La cercanía entre CV y prueba indica que los modelos generalizan dentro de este dataset, sin sobreajuste marcado. *Los tres mejores modelos son estadísticamente comparables* (diferencias <1 punto en prueba): la CNN, que aprende de los píxeles, y los modelos clásicos (SVM y Random Forest), que usan características diseñadas a mano, alcanzan resultados equivalentes. Esto sugiere que, a esta escala de datos, las características de color son muy informativas y una CNN pequeña no aporta una ventaja clara. Se reporta la SVM como mejor modelo por su F1-macro en validación cruzada, el criterio de selección que no usa el conjunto de prueba.

¿Qué funciona y qué falla? El sistema separa muy bien la fruta podrida (color marrón/oscuero) de la sana; los errores residuales ocurren entre buena y mala con iluminación o manchas ambiguas. Segmentar y usar características solo de la fruta fue decisivo: en una versión previa con el fondo incluido, la clase *regular* alcanzaba un 100 % irreal porque el modelo reconocía el fondo de los recortes; al enmascarar el fondo, la métrica bajó a valores realistas (0,96) y honestos.

Limitaciones. (i) La clase *regular* se construyó con recortes segmentados de la carpeta *Mixed* y aumento de datos, por lo que es menos diversa. (ii) Las imágenes provienen de un único dataset; el desempeño podría caer con cámaras, iluminación o variedades distintas (cambio de dominio). (iii) La estimación de tamaño depende de la calidad de la segmentación y de un fondo simple; sin referencia de escala, entrega un diámetro *relativo*, no absoluto. (iv) La segmentación (Sec. II) asume una sola fruta como objeto dominante: selecciona la componente conexa más grande que contrasta con el fondo, sin verificar que en efecto sea una manzana; con varias frutas, fondos complejos o presencia de otros objetos puede aislar (y por tanto clasificar) algo distinto de la manzana. (v) En la literatura, FruitNet reporta exactitudes del orden de 85–95 % con CNN;




Figura 4. Comparación de los cuatro modelos.

Matrices de confusión (conjunto de prueba)




Figura 5. Matrices de confusión normalizadas (prueba).

nuestros resultados son comparables, recordando que el dato es relativamente “limpio”.

VII. ASPECTOS ÉTICOS E IMPACTOS

Dilemas éticos identificados y decisiones tomadas, en relación directa con los principios del ACM Code of Ethics and Professional Conduct [7] (versión adoptada también por IEEE-CS).

Sesgo y equidad (Principio 1.4, “ser justo y no discriminar”): un modelo entrenado sobre un dataset de origen único (variedad, iluminación y cámara del conjunto de Kaggle) puede generalizar mal —y resultar injusto— con frutas de otros productores, regiones o condiciones de cultivo, perjudicando económicamente a quien lo use. **Decisión adoptada:** documentar el sesgo explícitamente (ver Limitaciones) y ampliar el conjunto con 116 fotografías propias, capturadas en




Figura 6. Importancia de características (Random Forest).

condiciones distintas a las del dataset original, como medida concreta y reproducible de mitigación.

Privacidad y consentimiento (Principios 1.6 “respetar la privacidad” y 1.7 “honrar la confidencialidad”): varias fotografías —tanto del dataset público como las propias— muestran manos o superficies que podrían identificar a una persona o un lugar. **Decisión adoptada:** (a) las fotografías propias fueron tomadas y aportadas por los mismos autores, quienes consintieron expresamente su uso académico y su publicación en el repositorio del curso; (b) no se almacenan ni publican metadatos personales (geolocalización, EXIF, nombres); (c) la segmentación recorta el fondo *antes* de calcular características, lo que de paso reduce la información personal retenida en el pipeline de cómputo.

Honestidad académica e integridad (Principios 1.3 “ser honesto y confiable” y 2.5 “dar evaluaciones completas y objetivas”): se decidió reportar, en vez de omitir, el episodio en que la clase *regular* alcanzó un F1 irreal de 100 % por una fuga de información del fondo (Sec. VI), y elegir el modelo final por validación cruzada —nunca por el conjunto de prueba— para no inflar artificialmente la cifra que se reporta. Se referencian explícitamente el dataset de terceros [3] y las bibliotecas usadas [6].

Uso responsable y prevención de daño (Principio 1.2 “evitar daño”): una predicción errónea de calidad tiene costo económico (descartar fruta sana) o sanitario (aceptar fruta en mal estado). **Decisión adoptada:** presentar el sistema como *herramienta de apoyo a la decisión humana*, no como reemplazo de un clasificador experto; publicar el F1 por clase (Tabla II) para que cualquier usuario sepa en qué clase el sistema es menos confiable; y documentar explícitamente el supuesto de operación —una sola fruta sobre fondo simple— y sus consecuencias (párrafo de Limitaciones, Sec. VI), de modo que quien despliegue o evalúe el sistema entienda *cuándo* confiar menos en la predicción (p. ej., con varias frutas u objetos ajenos en la imagen, la segmentación puede describir algo distinto de la manzana).

La Tabla III resume estos cuatro dilemas, el principio

Cuadro III
DILEMAS ÉTICOS IDENTIFICADOS, PRINCIPIO DEL CÓDIGO ACM/IEEE INVOLUCRADO Y MEDIDA CONCRETA ADOPTADA EN EL PROYECTO.

Dilema	Principio (ACM/IEEE [7])	Medida adoptada
Sesgo de origen único	1.4 Ser justo y no discriminar	Documentar el sesgo; ampliar el dataset con 116 fotos propias en condiciones distintas
Privacidad / consentimiento	1.6 Privacidad; 1.7 Confidencialidad	Fotos propias con consentimiento expreso de los autores; sin metadatos personales; recorte del fondo antes de procesar
Honestidad académica	1.3 Honestidad; 2.5 Evaluación objetiva y completa	Reportar la fuga de información detectada; seleccionar por CV (no por prueba); citar fuentes de datos y software
Riesgo de daño / uso responsable	1.2 Evitar daño	Presentar el sistema como apoyo a la decisión humana; publicar F1 por clase; documentar el supuesto de operación (una fruta, fondo simple) y sus límites

concreto del código de ética que cada uno involucra y la medida adoptada en el proyecto.

Análisis de impactos y estrategias de mitigación. La Tabla IV resume, para cada dimensión exigida por la guía, el argumento técnico-ético y la estrategia concreta propuesta para potenciar los beneficios y mitigar los riesgos.

VIII. CONCLUSIONES Y TRABAJO FUTURO

Se construyó un sistema reproducible que clasifica la calidad de la manzana en tres clases y estima su tamaño, comparando cuatro modelos bajo el mismo protocolo. La **SVM-RBF sobre características de la fruta segmentada** fue el mejor modelo por validación cruzada (F1-macro 0,967), con la CNN y Random Forest a un nivel equivalente en el conjunto de prueba ($\approx 0,95$). El mayor aprendizaje fue metodológico: *segmentar y medir solo la fruta evita un sesgo de fondo que inflaba artificialmente las métricas*. Como trabajo futuro: ampliar y diversificar el dataset (más fotos propias y otras variedades, condiciones de captura distintas), usar transferencia de aprendizaje, segmentación con redes (U-Net) y una referencia de escala para obtener tamaño absoluto.

ENLACES

Video (máx. 10 min): <https://youtu.be/27Uq-99Mdik>

Repositorio (código documentado): <https://github.com/JEGH18/ProyectoFinalAPO3>

REFERENCIAS

- [1] FAO, “Pérdidas y desperdicio de alimentos,” 2019.
- [2] Naciones Unidas, “Objetivos de Desarrollo Sostenible,” 2015. [En línea]. <https://www.un.org/sustainabledevelopment/es/>
- [3] R. Park, “Fruit Quality Classification,” Kaggle, 2023. [En línea]. <https://www.kaggle.com/datasets/ryandpark/fruit-quality-classification>
- [4] C. Cortes y V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.

Cuadro IV
MATRIZ DE IMPACTOS: ANÁLISIS POR DIMENSIÓN Y ESTRATEGIA DE MITIGACIÓN/POTENCIACIÓN PROPUESTA.

Dimensión	Análisis (beneficio / riesgo)	Estrategia propuesta
Económico	Reduce el descarte de fruta vendible y agiliza la clasificación; pero un falso “mala” desecha producto sano y un falso “buena” puede dañar la reputación del vendedor (Tabla II cuantifica ese riesgo por clase)	Calibrar el umbral de decisión según el costo asimétrico del caso de uso y mantener supervisión humana en las predicciones de menor confianza
Ambiental	Menos desperdicio implica ahorrar el agua, el suelo y la energía ya invertidos en la fruta descartada (huella evitada); los modelos clásicos corren en CPU, con bajo consumo frente a redes profundas grandes	Preferir en producción el modelo clásico (SVM o Random Forest) sobre la CNN cuando el desempeño sea equivalente —como ocurre aquí (Tabla I)—, pues reduce el cómputo y la huella de carbono del despliegue
Social	Estandariza un criterio hoy subjetivo y reduce la exposición de operarios a tareas repetitivas; pero puede desplazar empleo de clasificación manual	Comunicar el sistema como herramienta de <i>apoyo</i> (no reemplazo, como se argumentó arriba) y acompañar su adopción con programas de capacitación hacia tareas de supervisión y control de calidad
Global	Contribuye a los Objetivos de Desarrollo Sostenible 2 (Hambre cero) y 12 (Producción y consumo responsables) [2], al atacar directamente las pérdidas poscosecha que documenta la FAO [1]	Publicar el código y el modelo (Sec. Enlaces) para que comunidades agrícolas de otras regiones lo adapten a sus propias variedades, mitigando a la vez el sesgo de origen único




Figura 7. Proyección PCA del espacio de características.

Ejemplos de predicción (SVM): calidad y tamaño




Figura 8. Ejemplos de predicción de calidad y tamaño (SVM).

- [5] D. P. Kingma y J. Ba, “Adam: A method for stochastic optimization,” *ICLR*, 2015.
- [6] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *JMLR*, vol. 12, pp. 2825–2830, 2011.
- [7] ACM, “ACM Code of Ethics and Professional Conduct,” 2018.