

Clasificación de la calidad y estimación del tamaño de manzanas mediante visión por computador: comparación de modelos clásicos y una red neuronal convolucional

COMPLETAR: Integrante 1
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
COMPLETAR: correo@u.icesi.edu.co

COMPLETAR: Integrante 2
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
COMPLETAR: correo@u.icesi.edu.co

COMPLETAR: Integrante 3
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
COMPLETAR: correo@u.icesi.edu.co

Resumen—La clasificación manual de la calidad de frutas es lenta, subjetiva y propensa a errores, lo que genera pérdidas económicas y desperdicio de alimentos. Se desarrolla un sistema de visión por computador que, a partir de la fotografía de una manzana, predice su *calidad* (buena, regular, mala) y estima su *tamaño* (diámetro normalizado y clase pequeño/mediano/grande). Se segmenta la fruta para calcular un descriptor de 49 características de color, textura y defectos *solo sobre la fruta* (invariante al fondo), y se comparan, bajo el mismo protocolo, tres modelos clásicos (regresión logística, SVM-RBF y Random Forest) y una red neuronal convolucional (CNN). Sobre 3006 imágenes (2890 del dataset público y 116 propias), los cuatro modelos alcanzaron un desempeño comparable en prueba (F1-macro 0,94–0,95); por validación cruzada la SVM-RBF fue la mejor (0,967), muy por encima de la línea base logística (0,838). Se sigue la metodología CRISP-DM y se discuten el sesgo de los datos, la validez de los resultados y los aspectos éticos.

Index Terms—visión por computador, clasificación de calidad, segmentación, SVM, Random Forest, CNN, estimación de tamaño, CRISP-DM.

I. INTRODUCCIÓN

En mercados y agroindustrias, la clasificación de productos frescos según madurez, tamaño o defectos se hace de forma manual: un proceso lento, subjetivo y costoso que contribuye a pérdidas y desperdicio de alimentos [1]. Automatizarla con visión por computador permite acelerar el proceso y estandarizar criterios.

Este proyecto desarrolla un sistema que, dada la foto de una manzana sobre fondo simple, entrega dos salidas exigidas por el caso de estudio: (i) la *clase de calidad* en tres categorías (buena, regular, mala) y (ii) una *estimación de tamaño*. La justificación es directa: reducir pérdidas poscosecha tiene impacto económico, social y ambiental. El aporte técnico se concentra en un descriptor de color/textura calculado únicamente sobre la fruta segmentada (evitando que el modelo aprenda el fondo), la comparación rigurosa de cuatro modelos y un análisis crítico de la validez de los resultados.

II. FUNDAMENTOS TEÓRICOS

Espacio HSV e histogramas. El color es el principal indicador de calidad de la fruta. Se trabaja en el espacio HSV, que separa el tono (Matiz) de la intensidad. El histograma normalizado de un canal, $h_b = \frac{1}{N} \sum_p \mathbb{K}[c_p \in \text{bin}_b]$, cumple $\sum_b h_b = 1$ y es invariante al número de píxeles (y a la resolución).

Estandarización (z-score). Cada característica se reescala como $z = (x - \mu)/\sigma$, con μ, σ estimados solo en entrenamiento. Es necesaria para SVM-RBF, la regresión logística y la red neuronal, sensibles a la escala.

Segmentación y tamaño. La fruta se separa del fondo con un umbral de Otsu sobre la distancia al color de fondo (estimado en los bordes). El tamaño se mide con el diámetro equivalente del área segmentada, $d_{eq} = 2\sqrt{A/\pi}$, normalizado por el lado de la imagen (invariante a la resolución).

Modelos. La *regresión logística* (línea base) modela $P(y=k | \mathbf{x})$ con softmax. La *SVM* busca el hiperplano de máximo margen y usa el kernel RBF $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$ para fronteras no lineales [3]. El *Random Forest* promedia múltiples árboles con muestreo aleatorio, reduciendo la varianza. La *CNN* aprende filtros sobre los píxeles mediante capas Conv-ReLU-Pooling y minimiza la entropía cruzada $\mathcal{L} = -\frac{1}{n} \sum_i \sum_k y_{ik} \log p_{ik}$ por retropropagación con Adam [4].

Métricas. A partir de la matriz de confusión se calculan precisión, exhaustividad (*recall*) y $F1 = 2PR/(P + R)$ por clase; se reporta el **F1-macro** (promedio entre clases), adecuado ante el desbalance, validado con validación cruzada estratificada de 5 pliegues.

III. METODOLOGÍA

Se aplicó CRISP-DM (Fig. 1) con evidencia en cada fase.

Datos. Se usó el conjunto público *Fruit Quality Classification* de Kaggle [2], subconjunto de manzanas: *buena* (1149, *Apple_Good*) y *mala* (1141, *Apple_Bad*). La clase *regular* se construyó, según indica el caso de estudio, segmentando individualmente cada fruta de la carpeta *Mixed Quality* (177

Aplicación de CRISP-DM al proyecto




Figura 1. Aplicación concreta de CRISP-DM al proyecto.




Figura 2. Distribución del tamaño medido (arriba) y de las clases de calidad (abajo).

ejemplares recortados) y aumentándola con transformaciones (volteos, rotaciones, brillo) hasta 600 muestras para reducir el desbalance. Además, se recolectaron y añadieron **116 fotografías propias** tomadas para este proyecto (48 sanas, 38 intermedias y 30 dañadas), como exige el caso de estudio, integradas a las tres clases. En total, **3006 imágenes** (buena 1197, regular 638, mala 1171). Las Figs. 2 muestran la distribución de calidad y tamaño.

Preparación y características. Cada imagen se redimensiona a 128×128 (elimina el sesgo de resolución) y se segmenta la fruta (Fig. 3). Sobre los píxeles de la fruta se calcula un vector de **49 características**: histogramas de H/S/V (16/8/8), media y desviación de R,G,B,H,S,V (12), estadísticos de gradiente (2, textura), proporción de píxeles oscuros y marrones (2, defectos) y entropía de matiz (1). *Calcular las características solo sobre la fruta es una decisión clave:* evita



Figura 3. Segmentación de la fruta y estimación de tamaño (diámetro normalizado).

que los modelos aprendan el fondo (césped, mano, mesa) en lugar de la calidad.

Modelado. Partición estratificada 70/30 (2104 entrenamiento, 902 prueba, semilla 42) y estandarización ajustada en entrenamiento. Se entrenaron, con `class_weight` balanceado, tres modelos clásicos con búsqueda en rejilla y validación cruzada de 5 pliegues (regresión logística, SVM-RBF, Random Forest) y una CNN pequeña (3 bloques convolucionales + 2 capas densas, entrada 64×64 enmascarada, Adam, entropía cruzada con pesos). El sistema selecciona automáticamente el mejor modelo por F1-macro en validación cruzada.

Despliegue. Aplicación en Streamlit que permite cargar una imagen o capturarla con la cámara y muestra calidad, tamaño y segmentación.

IV. RESULTADOS

La Tabla I, la Tabla II y la Fig. 4 resumen el desempeño. El modelo se selecciona por validación cruzada (sin usar el conjunto de prueba): la **SVM-RBF fue la mejor (F1-macro CV 0,967)**, seguida de Random Forest (0,950) y la regresión logística (0,856). En el conjunto de prueba los tres mejores modelos quedaron *prácticamente empatados* (SVM 0,949, CNN 0,953, Random Forest 0,944), muy por encima

Cuadro I
RESULTADOS GLOBALES ($n_{prueba} = 902$). EL MEJOR MODELO SE ELIGE
POR F1-MACRO EN VALIDACIÓN CRUZADA (CV).

Modelo	Exactitud	F1-macro	F1-macro CV
Regresión logística	0.837	0.838	0.856
SVM (RBF)	0.948	0.949	0.967
Random Forest	0.943	0.944	0.950
CNN (3 conv.)	0.951	0.953	—

Cuadro II
F1 POR CLASE (PRUEBA).

Modelo	Buena	Regular	Mala
Reg. logística	0.82	0.84	0.85
SVM (RBF)	0.94	0.96	0.95
Random Forest	0.94	0.95	0.95
CNN	0.94	0.96	0.95

de la línea base (0,838); la cercanía entre CV y prueba indica ausencia de sobreajuste severo. Las matrices de confusión (Fig. 5) muestran que los errores se concentran entre *buena* y *mala*. La importancia de características (Fig. 6) confirma que los descriptores de color (saturación y matiz) son los más decisivos, coherente con la intuición agronómica. La proyección PCA (Fig. 7) muestra clases separables con zonas de solape, y la Fig. 8 ilustra predicciones de calidad y tamaño.

V. ANÁLISIS DE RESULTADOS

¿Generalizan? ¿Hay sobreajuste? La cercanía entre CV y prueba indica que los modelos generalizan dentro de este dataset, sin sobreajuste marcado. *Los tres mejores modelos son estadísticamente comparables* (diferencias <1 punto en prueba): la CNN, que aprende de los píxeles, y los modelos clásicos (SVM y Random Forest), que usan características diseñadas a mano, alcanzan resultados equivalentes. Esto sugiere que, a esta escala de datos, las características de color son muy informativas y una CNN pequeña no aporta una ventaja clara. Se reporta la SVM como mejor modelo por su F1-macro en validación cruzada, el criterio de selección que no usa el conjunto de prueba.

¿Qué funciona y qué falla? El sistema separa muy bien la fruta podrida (color marrón/oscuro) de la sana; los errores residuales ocurren entre buena y mala con iluminación o manchas ambiguas. Segmentar y usar características solo de la fruta fue decisivo: en una versión previa con el fondo incluido, la clase *regular* alcanzaba un 100 % irreal porque el modelo reconocía el fondo de los recortes; al enmascarar el fondo, la métrica bajó a valores realistas (0,96) y honestos.

Limitaciones. (i) La clase *regular* se construyó con recortes segmentados de la carpeta *Mixed* y aumento de datos, por lo que es menos diversa. (ii) Las imágenes provienen de un único dataset; el desempeño podría caer con cámaras, iluminación o variedades distintas (cambio de dominio). (iii) La estimación de tamaño depende de la calidad de la segmentación y de un fondo simple; sin referencia de escala, entrega un diámetro *relativo*, no absoluto. (iv) En la literatura, FruitNet reporta




Figura 4. Comparación de los cuatro modelos.




Figura 5. Matrices de confusión normalizadas (prueba).

exactitudes del orden de 85–95 % con CNN; nuestros resultados son comparables, recordando que el dato es relativamente “limpio”.

VI. ASPECTOS ÉTICOS E IMPACTOS

Ética (código ACM/IEEE [6]). *Sesgo y equidad:* el modelo entrenado en un dataset específico puede ser injusto con frutas de otros orígenes; se mitiga documentando el sesgo y permitiendo recolección propia. *Privacidad:* algunas imágenes contienen manos; no se almacenan datos personales y deben usarse con consentimiento. *Uso responsable:* es una herramienta de *apoyo*; un error tiene costo económico, por lo que se recomienda supervisión humana. *Integridad:* se referencian explícitamente los datos y el código de terceros (el dataset de Kaggle [2] y las bibliotecas [5]), tal como exige la honestidad académica.




Figura 6. Importancia de características (Random Forest).

Impactos. *Económico:* menos fruta buena descartada y clasificación más rápida reducen costos. *Ambiental:* disminuir el desperdicio evita malgastar el agua, suelo y energía incorporados a la fruta; los modelos clásicos tienen huella de cómputo baja (sin GPU). *Social:* estandariza un criterio hoy subjetivo, aunque debe acompañarse de capacitación laboral. *Global:* aporta a los ODS 2 (hambre cero) y 12 (producción y consumo responsables).

VII. CONCLUSIONES Y TRABAJO FUTURO

Se construyó un sistema reproducible que clasifica la calidad de la manzana en tres clases y estima su tamaño, comparando cuatro modelos bajo el mismo protocolo. La **SVM-RBF sobre características de la fruta segmentada** fue el mejor modelo por validación cruzada (F1-macro 0,967), con la CNN y Random Forest a un nivel equivalente en el conjunto de prueba ($\approx 0,95$). El mayor aprendizaje fue metodológico: *segmentar y medir solo la fruta evita un sesgo de fondo que inflaba artificialmente las métricas*. Como trabajo futuro: ampliar y diversificar el dataset (más fotos propias y otras variedades, condiciones de captura distintas), usar transferencia de aprendizaje, segmentación con redes (U-Net) y una referencia de escala para obtener tamaño absoluto.

ENLACES

Video (máx. 10 min): [COMPLETAR:enlacedelvideo](#)

Repositorio (código documentado): [COMPLETAR:https://github.com/usuario/proyectoAPo3FInal](https://github.com/usuario/proyectoAPo3FInal)

REFERENCIAS

- [1] FAO, "Pérdidas y desperdicio de alimentos," 2019.
- [2] R. Park, "Fruit Quality Classification," Kaggle, 2023. [En línea]. <https://www.kaggle.com/datasets/ryandpark/fruit-quality-classification>
- [3] C. Cortes y V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [4] D. P. Kingma y J. Ba, "Adam: A method for stochastic optimization," *ICLR*, 2015.
- [5] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *JMLR*, vol. 12, pp. 2825–2830, 2011.
- [6] ACM, "ACM Code of Ethics and Professional Conduct," 2018.




Figura 7. Proyección PCA del espacio de características.



Figura 8. Ejemplos de predicción de calidad y tamaño (SVM).