

Clasificación de la calidad y estimación del tamaño de manzanas mediante visión por computador: comparación de modelos clásicos y una red neuronal convolucional

COMPLETAR: Integrante 1
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
COMPLETAR: correo@u.icesi.edu.co

COMPLETAR: Integrante 2
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
COMPLETAR: correo@u.icesi.edu.co

COMPLETAR: Integrante 3
Algoritmos y Programación III
Universidad ICESI, Cali, Colombia
COMPLETAR: correo@u.icesi.edu.co

Resumen—La clasificación manual de la calidad de frutas es lenta, subjetiva y propensa a errores, lo que genera pérdidas económicas y desperdicio de alimentos. Se desarrolla un sistema de visión por computador que, a partir de la fotografía de una manzana, predice su *calidad* (buena, regular, mala) y estima su *tamaño* (diámetro normalizado y clase pequeño/mediano/grande). Se segmenta la fruta para calcular un descriptor de 49 características de color, textura y defectos *solo sobre la fruta* (invariante al fondo), y se comparan, bajo el mismo protocolo, tres modelos clásicos (regresión logística, SVM-RBF y Random Forest) y una red neuronal convolucional (CNN). Sobre 2976 imágenes (2890 del dataset público y 86 propias), la SVM logró la mejor F1-macro de prueba (0,960), seguida de Random Forest (0,951) y la CNN (0,944), superando claramente a la línea base logística (0,841). Se sigue la metodología CRISP-DM y se discuten el sesgo de los datos, la validez de los resultados y los aspectos éticos.

Index Terms—visión por computador, clasificación de calidad, segmentación, SVM, Random Forest, CNN, estimación de tamaño, CRISP-DM.

I. INTRODUCCIÓN

En mercados y agroindustrias, la clasificación de productos frescos según madurez, tamaño o defectos se hace de forma manual: un proceso lento, subjetivo y costoso que contribuye a pérdidas y desperdicio de alimentos [1]. Automatizarla con visión por computador permite acelerar el proceso y estandarizar criterios.

Este proyecto desarrolla un sistema que, dada la foto de una manzana sobre fondo simple, entrega dos salidas exigidas por el caso de estudio: (i) la *clase de calidad* en tres categorías (buena, regular, mala) y (ii) una *estimación de tamaño*. La justificación es directa: reducir pérdidas poscosecha tiene impacto económico, social y ambiental. El aporte técnico se concentra en un descriptor de color/textura calculado únicamente sobre la fruta segmentada (evitando que el modelo aprenda el fondo), la comparación rigurosa de cuatro modelos y un análisis crítico de la validez de los resultados.

II. FUNDAMENTOS TEÓRICOS

Espacio HSV e histogramas. El color es el principal indicador de calidad de la fruta. Se trabaja en el espacio HSV,

que separa el tono (Matiz) de la intensidad. El histograma normalizado de un canal, $h_b = \frac{1}{N} \sum_p \mathbb{I}[c_p \in \text{bin}_b]$, cumple $\sum_b h_b = 1$ y es invariante al número de píxeles (y a la resolución).

Estandarización (z-score). Cada característica se reescala como $z = (x - \mu)/\sigma$, con μ, σ estimados solo en entrenamiento. Es necesaria para SVM-RBF, la regresión logística y la red neuronal, sensibles a la escala.

Segmentación y tamaño. La fruta se separa del fondo con un umbral de Otsu sobre la distancia al color de fondo (estimado en los bordes). El tamaño se mide con el diámetro equivalente del área segmentada, $d_{eq} = 2\sqrt{A/\pi}$, normalizado por el lado de la imagen (invariante a la resolución).

Modelos. La *regresión logística* (línea base) modela $P(y=k | \mathbf{x})$ con softmax. La *SVM* busca el hiperplano de máximo margen y usa el kernel RBF $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$ para fronteras no lineales [3]. El *Random Forest* promedia múltiples árboles con muestreo aleatorio, reduciendo la varianza. La *CNN* aprende filtros sobre los píxeles mediante capas Conv-ReLU-Pooling y minimiza la entropía cruzada $\mathcal{L} = -\frac{1}{n} \sum_i \sum_k y_{ik} \log p_{ik}$ por retropropagación con Adam [4].

Métricas. A partir de la matriz de confusión se calculan precisión, exhaustividad (*recall*) y $F1 = 2PR/(P + R)$ por clase; se reporta el **F1-macro** (promedio entre clases), adecuado ante el desbalance, validado con validación cruzada estratificada de 5 pliegues.

III. METODOLOGÍA

Se aplicó CRISP-DM (Fig. 1) con evidencia en cada fase.

Datos. Se usó el conjunto público *Fruit Quality Classification* de Kaggle [2], subconjunto de manzanas: *buena* (1149, *Apple_Good*) y *mala* (1141, *Apple_Bad*). La clase *regular* se construyó, según indica el caso de estudio, segmentando individualmente cada fruta de la carpeta *Mixed Quality* (177 ejemplares recortados) y aumentándola con transformaciones (volteos, rotaciones, brillo) hasta 600 muestras para reducir

Aplicación de CRISP-DM al proyecto




Figura 1. Aplicación concreta de CRISP-DM al proyecto.




Figura 2. Distribución del tamaño medido (arriba) y de las clases de calidad (abajo).

el desbalance. Además, se recolectaron y añadieron **86 fotografías propias** tomadas para este proyecto (48 sanas y 38 intermedias), como exige el caso de estudio, integradas a las clases buena y regular. En total, **2976 imágenes** (buena 1197, regular 638, mala 1141). Las Figs. 2 muestran la distribución de calidad y tamaño.

Preparación y características. Cada imagen se redimensiona a 128×128 (elimina el sesgo de resolución) y se segmenta la fruta (Fig. 3). Sobre los píxeles de la fruta se calcula un vector de **49 características**: histogramas de H/S/V (16/8/8), media y desviación de R,G,B,H,S,V (12), estadísticos de gradiente (2, textura), proporción de píxeles oscuros y marrones (2, defectos) y entropía de matiz (1). *Calcular las características solo sobre la fruta es una decisión clave*: evita que los modelos aprendan el fondo (césped, mano, mesa) en lugar de la calidad.



Figura 3. Segmentación de la fruta y estimación de tamaño (diámetro normalizado).

Modelado. Partición estratificada 70/30 (2083 entrenamiento, 893 prueba, semilla 42) y estandarización ajustada en entrenamiento. Se entrenaron, con `class_weight` balanceado, tres modelos clásicos con búsqueda en rejilla y validación cruzada de 5 pliegues (regresión logística, SVM-RBF, Random Forest) y una CNN pequeña (3 bloques convolucionales + 2 capas densas, entrada 64×64 enmascarada, Adam, entropía cruzada con pesos). El sistema selecciona automáticamente el mejor modelo por F1-macro.

Despliegue. Aplicación en Streamlit que permite cargar una imagen o capturarla con la cámara y muestra calidad, tamaño y segmentación.

IV. RESULTADOS

La Tabla I, la Tabla II y la Fig. 4 resumen el desempeño en el conjunto de prueba. La SVM-RBF obtuvo la mejor F1-macro (0,960), seguida por Random Forest (0,951) y la CNN (0,944); la regresión logística, como línea base, quedó claramente por debajo (0,841). La validación cruzada fue consistente con la prueba (p.ej. SVM: 0,964 en CV frente a 0,960 en prueba), lo que indica ausencia de sobreajuste severo. Las matrices de confusión (Fig. 5) muestran que los errores se concentran entre *buena* y *mala*. La importancia de

Cuadro I
RESULTADOS GLOBALES (PRUEBA, $n = 893$).

Modelo	Exactitud	F1-macro	F1-macro CV
Regresión logística	0.837	0.841	0.855
SVM (RBF)	0.959	0.960	0.964
Random Forest	0.951	0.951	0.956
CNN (3 conv.)	0.944	0.944	—

Cuadro II
F1 POR CLASE (PRUEBA).

Modelo	Buena	Regular	Mala
Reg. logística	0.81	0.87	0.84
SVM (RBF)	0.95	0.97	0.96
Random Forest	0.95	0.95	0.95
CNN	0.94	0.95	0.95

características (Fig. 6) confirma que los descriptores de color (saturación y matiz) son los más decisivos, coherente con la intuición agronómica. La proyección PCA (Fig. 7) muestra clases separables con zonas de solape, y la Fig. 8 ilustra predicciones de calidad y tamaño.

V. ANÁLISIS DE RESULTADOS

¿Generalizan? ¿Hay sobreajuste? La cercanía entre CV y prueba indica que los modelos generalizan dentro de este dataset, sin sobreajuste marcado. La SVM y Random Forest dominan; la CNN, entrenada desde cero con $\sim 2,9k$ imágenes, queda ligeramente por debajo: *con pocos datos, las características diseñadas a mano más una SVM superan a una CNN pequeña*, un hallazgo coherente con la literatura cuando los datos son limitados.

¿Qué funciona y qué falla? El sistema separa muy bien la fruta podrida (color marrón/oscuro) de la sana; los errores residuales ocurren entre buena y mala con iluminación o manchas ambiguas. Segmentar y usar características solo de la fruta fue decisivo: en una versión previa con el fondo incluido, la clase *regular* alcanzaba un 100 % irreal porque el modelo reconocía el fondo de los recortes; al enmascarar el fondo, la métrica bajó a valores realistas (0,96) y honestos.

Limitaciones. (i) La clase *regular* se construyó con recortes segmentados de la carpeta *Mixed* y aumento de datos, por lo que es menos diversa. (ii) Las imágenes provienen de un único dataset; el desempeño podría caer con cámaras, iluminación o variedades distintas (cambio de dominio). (iii) La estimación de tamaño depende de la calidad de la segmentación y de un fondo simple; sin referencia de escala, entrega un diámetro *relativo*, no absoluto. (iv) En la literatura, FruitNet reporta exactitudes del orden de 85–95 % con CNN; nuestros resultados son comparables, recordando que el dato es relativamente “limpio”.

VI. ASPECTOS ÉTICOS E IMPACTOS

Ética (código ACM/IEEE [6]). *Sesgo y equidad:* el modelo entrenado en un dataset específico puede ser injusto con frutas de otros orígenes; se mitiga documentando el sesgo y




Figura 4. Comparación de los cuatro modelos.

Matrices de confusión (conjunto de prueba)




Figura 5. Matrices de confusión normalizadas (prueba).

permitiendo recolección propia. *Privacidad:* algunas imágenes contienen manos; no se almacenan datos personales y deben usarse con consentimiento. *Uso responsable:* es una herramienta de *apoyo*; un error tiene costo económico, por lo que se recomienda supervisión humana. *Integridad:* se referencian explícitamente los datos y el código de terceros (el dataset de Kaggle [2] y las bibliotecas [5]), tal como exige la honestidad académica.

Impactos. *Económico:* menos fruta buena descartada y clasificación más rápida reducen costos. *Ambiental:* disminuir el desperdicio evita malgastar el agua, suelo y energía incorporados a la fruta; los modelos clásicos tienen huella de cómputo baja (sin GPU). *Social:* estandariza un criterio hoy subjetivo, aunque debe acompañarse de capacitación laboral. *Global:* aporta a los ODS 2 (hambre cero) y 12 (producción y consumo responsables).




Figura 6. Importancia de características (Random Forest).




Figura 7. Proyección PCA del espacio de características.

VII. CONCLUSIONES Y TRABAJO FUTURO

Se construyó un sistema reproducible que clasifica la calidad de la manzana en tres clases y estima su tamaño, comparando cuatro modelos bajo el mismo protocolo. La **SVM-RBF sobre características de la fruta segmentada** fue la mejor opción (F1-macro 0,960), por encima de una CNN entrenada desde cero a esta escala de datos. El mayor aprendizaje fue metodológico: *segmentar y medir solo la fruta evita un sesgo de fondo que inflaba artificialmente las métricas*. Como trabajo futuro: ampliar y diversificar el dataset (más fotos propias y otras variedades, condiciones de captura distintas), usar transferencia de aprendizaje, segmentación con redes (U-Net) y una referencia de escala para obtener tamaño absoluto.

ENLACES

Video (máx. 10 min): [COMPLETAR:enlacedelvideo](#)
Repositorio (código documentado): [COMPLETAR:https://github.com/usuario/proyectoAPo3FInal](#)

REFERENCIAS

- [1] FAO, "Pérdidas y desperdicio de alimentos," 2019.

Ejemplos de predicción (SVM): calidad y tamaño




Figura 8. Ejemplos de predicción de calidad y tamaño (SVM).

- [2] R. Park, "Fruit Quality Classification," Kaggle, 2023. [En línea]. <https://www.kaggle.com/datasets/ryandpark/fruit-quality-classification>
[3] C. Cortes y V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
[4] D. P. Kingma y J. Ba, "Adam: A method for stochastic optimization," *ICLR*, 2015.
[5] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *JMLR*, vol. 12, pp. 2825–2830, 2011.
[6] ACM, "ACM Code of Ethics and Professional Conduct," 2018.